

Ποιοτική Αξιολόγηση της Μετάφρασης

Κωστούλας Ευάγγελος

Η αξιολόγηση σχεδιάστηκε ώστε να εξετάζει την επίδραση της κβάντισης σε περισσότερα από ένα επίπεδα. Οι γενικές μετρικές ποιότητας, όπως το COMET και το chrF++, μπορούν να δείξουν αν μια κβαντισμένη παραλλαγή είναι συνολικά καλύτερη ή χειρότερη, αλλά δεν εξηγούν απαραίτητα **πώς** μεταβάλλεται η μετάφραση.

Για τον λόγο αυτό, η ανάλυση οργανώθηκε σε τέσσερα επίπεδα:

- Συνολική μεταφραστική ποιότητα.
- Επίδραση σε ειδικές γλωσσικές προκλήσεις.
- Μορφολογικές και συντακτικές αποκλίσεις και διατήρηση πληροφοριών.
- Παραισθήσεις, παραλείψεις και γενικότερη πιστότητα.

Σε όλες τις αναλύσεις, κάθε κβαντισμένη παραλλαγή συγκρίθηκε με το **Πλήρες Μοντέλο (Full Model) από το οποίο προέκυψε**. Η επιλογή αυτή ήταν απαραίτητη, επειδή τα μοντέλα έχουν διαφορετικό αρχικό επίπεδο ποιότητας. Επομένως, το βασικό ερώτημα δεν ήταν αν ένα μοντέλο είναι συνολικά καλύτερο από ένα άλλο, αλλά πόσο και με ποιον τρόπο μεταβάλλεται το ίδιο μοντέλο μετά την κβάντιση.

Οι δύο κατευθύνσεις, EN→GR και GR→EN, εξετάστηκαν χωριστά, καθώς παρουσίασαν διαφορετικό βαθμό δυσκολίας και διαφορετικές μορφές υποβάθμισης.

1. Συνολική μεταφραστική ποιότητα

1.1 Στόχος της ανάλυσης

Το πρώτο επίπεδο αξιολόγησης εξετάζει αν η κβάντιση διατηρεί τη γενική ποιότητα της μετάφρασης. Για τον σκοπό αυτό χρησιμοποιήθηκαν κυρίως οι μετρικές:

- COMET,
- chrF++.

Το COMET χρησιμοποιήθηκε ως η κύρια μετρική αξιολόγησης, επειδή εξετάζει αν η μετάφραση αποδίδει σωστά το νόημα της πηγής σε σχέση με τη μετάφραση αναφοράς. Το chrF++ χρησιμοποιήθηκε συμπληρωματικά, καθώς εξετάζει την ομοιότητα σε επίπεδο χαρακτήρων και λέξεων και είναι ιδιαίτερα χρήσιμο για γλώσσες με πλούσια μορφολογία, όπως τα ελληνικά.

Οι τιμές παρουσιάζονται χωριστά για:

- EN→GR,
- GR→EN.

Ο συνολικός μέσος όρος υπολογίστηκε ως συνοπτική ένδειξη της συνολικής επίδοσης, αλλά δεν χρησιμοποιήθηκε ως βάση ερμηνείας, επειδή μπορεί να αποκρύψει σημαντικές διαφορές μεταξύ των δύο κατευθύνσεων μετάφρασης, όπως στην περίπτωση του Mistral.

1.2 Κύρια ευρήματα

Τα αποτελέσματα δείχνουν ότι οι περισσότερες 4-bit και 8-bit μέθοδοι διατήρησαν μεγάλο μέρος της αρχικής ποιότητας. Αντίθετα, οι 2-bit τεχνικές παρουσίασαν πολύ μεγαλύτερη μεταβλητότητα και αρκετές από αυτές οδήγησαν σε σοβαρή κατάρρευση.

Το NLLB παρουσίασε τη μεγαλύτερη συνολική ανθεκτικότητα στην κβάντιση. Αρκετές από τις κβαντισμένες εκδόσεις του παρέμειναν πολύ κοντά στο Πλήρες Μοντέλο και στις δύο κατευθύνσεις.

Το Llama Krikri διατήρησε επίσης υψηλή ποιότητα στις περισσότερες 4-bit και 8-bit τεχνικές, αλλά οι πιο επιθετικές 2-bit παραλλαγές παρουσίασαν σημαντικές απώλειες.

Το Llama 3 ήταν σχετικά σταθερό στις καλύτερες 8-bit και 4-bit υλοποιήσεις, αλλά εμφάνισε ισχυρότερη κατάρρευση σε αρκετές 2-bit μεθόδους.

Το Mistral παρουσίασε μεγαλύτερη ασυμμετρία μεταξύ των δύο κατευθύνσεων. Η αρχική του επίδοση στην EN→GR ήταν ήδη χαμηλότερη, ενώ αρκετές επιθετικές κβαντίσεις επιδείνωσαν περαιτέρω τη συμπεριφορά του.

Συνολικά, η ικανότητα ενός μοντέλου να διατηρεί τη μεταφραστική του ποιότητα μετά την κβάντιση δεν καθορίζεται μόνο από τον αριθμό των bits. Επηρεάζεται επίσης από την αρχιτεκτονική του μοντέλου, τη συγκεκριμένη μέθοδο κβάντισης, τη γλώσσα-στόχο και τον τρόπο με τον οποίο η τεχνική χειρίζεται τα ακραία βάρη και τα πιο ευαίσθητα επίπεδα του δικτύου.

2. Επίδραση σε ειδικές γλωσσικές προκλήσεις

2.1 Στόχος της ανάλυσης

Η συνολική βαθμολογία μπορεί να παραμένει σταθερή, ενώ συγκεκριμένες κατηγορίες προτάσεων επηρεάζονται περισσότερο. Για τον λόγο αυτό εξετάστηκε αν η κβάντιση παρουσιάζει επιλεκτική αδυναμία σε προτάσεις με ιδιαίτερα γλωσσικά χαρακτηριστικά.

Επιλέχθηκαν τρεις βασικές κατηγορίες:

- προτάσεις με σπάνιες λέξεις,
- μεγάλες προτάσεις,
- προτάσεις από διαφορετικές θεματικές κατηγορίες.

Η επιλογή των κατηγοριών βασίστηκε στο πλαίσιο των έξι βασικών προκλήσεων της Νευρωνικής Μηχανικής Μετάφρασης [Six Challenges for Neural Machine Translation](#). Από τις προκλήσεις αυτές εξετάστηκαν οι **σπάνιες λέξεις**, οι **μεγάλες προτάσεις** και η πιθανή επίδραση του **θεματικού πεδίου**, καθώς μπορούσαν να μελετηθούν σε επίπεδο πρότασης με βάση τα διαθέσιμα δεδομένα.

Η αναντιστοιχία θεματικού πεδίου δεν μπορούσε να χαρακτηριστεί με βεβαιότητα ως *out-of-domain*, επειδή δεν ήταν γνωστά τα ακριβή δεδομένα εκπαίδευσης κάθε μοντέλου. Για τον λόγο αυτό, οι θεματικές κατηγορίες χρησιμοποιήθηκαν μόνο ως ενδεικτική σύγκριση, έχοντας ωστόσο τον περιορισμό του μικρού αριθμού προτάσεων σε ορισμένες κατηγορίες.

Οι υπόλοιπες προκλήσεις δεν εξετάστηκαν ως αυτοτελείς κατηγορίες. Η ποσότητα των δεδομένων εκπαίδευσης και η αναζήτηση δέσμης δεν μπορούσαν να απομονωθούν από τα διαθέσιμα αποτελέσματα. Η ευθυγράμμιση λέξεων αξιοποιήθηκε αργότερα ως εργαλείο αξιολόγησης της πιστότητας μέσω της προσέγγισης OTTAWA και όχι ως άμεση μελέτη της αντίστοιχης πρόκλησης του αρχικού άρθρου.

2.2 Κύρια ευρήματα

Στις περισσότερες κβαντισμένες παραλλαγές δεν παρατηρήθηκε σταθερή επιλεκτική υποβάθμιση, καθώς το 71% των μεθόδων εμφάνισε μέση πρόσθετη επίδραση μικρότερη από 0,01 COMET και το 89% μικρότερη από 0,02 COMET. Οι μεγαλύτερες επιλεκτικές αποκλίσεις εμφανίστηκαν κυρίως στις παραλλαγές στις οποίες είχε ήδη υποβαθμιστεί σημαντικά η συνολική μεταφραστική ποιότητα.

Δεν προέκυψε μία γλωσσική πρόκληση που να επηρεάζεται συστηματικά περισσότερο σε όλα τα μοντέλα και στις δύο κατευθύνσεις. Οι σπάνιες λέξεις παρουσίασαν ορισμένες αυξημένες αποκλίσεις, αλλά το πρόσημο και το μέγεθος της επίδρασης δεν ήταν σταθερά μεταξύ μοντέλων και κατευθύνσεων.

Οι μεγάλες προτάσεις παρουσίασαν μεγαλύτερη μεταβλητότητα, αλλά το διαθέσιμο δείγμα ήταν περιορισμένο. Για τον λόγο αυτό, τα αποτελέσματα χρησιμοποιήθηκαν ως ενδεικτικά και όχι ως ανεξάρτητο ισχυρό συμπέρασμα.

Εξετάστηκε επίσης η δυνατότητα ανάλυσης ανά θεματική κατηγορία. Ωστόσο, οι περισσότερες επιμέρους θεματικές περιείχαν πολύ λίγες προτάσεις. Η ανάλυση ανά θεματική κατηγορία κρίθηκε μη αντιπροσωπευτική και δεν χρησιμοποιήθηκε στα βασικά συμπεράσματα.

Στα ευρύτερα θεματικά πεδία δεν παρατηρήθηκε σταθερή κατεύθυνση επίδρασης. Οι διαφορές ήταν μικρές και παρουσίαζαν διαφορετικά πρόσημα μεταξύ των μεθόδων.

Το βασικό συμπέρασμα είναι ότι η κβάντιση δεν φαίνεται να δημιουργεί σταθερή αδυναμία απέναντι σε κάποια από τις γλωσσικές δυσκολίες που εξετάστηκαν. Οι επιλεκτικές επιπτώσεις εμφανίζονται κυρίως όταν η γενική ικανότητα του μοντέλου έχει ήδη αρχίσει να υποβαθμίζεται σημαντικά.

3. Μορφολογικές και συντακτικές αποκλίσεις και διατήρηση πληροφοριών

3.1 Στόχος της ανάλυσης

Οι γενικές μετρικές δεν μπορούν να δείξουν αν μια κβαντισμένη μετάφραση:

- αλλάζει απλώς τον τρόπο διατύπωσης,
- παρουσιάζει πραγματικό γραμματικό πρόβλημα,
- παραλείπει κρίσιμες πληροφορίες.

Για τον λόγο αυτό, η μορφολογική και συντακτική ανάλυση χωρίστηκε σε τρεις διακριτές ομάδες:

1. Δομικές ανακατασκευές.
2. Εσωτερικές γραμματικές ασυμφωνίες.
3. Διατήρηση πληροφοριών.

Ο διαχωρισμός αυτός ήταν σημαντικός, επειδή μια διαφορετική χρήση της παθητικής σύνταξης ή της γενικής δεν αποτελεί απαραίτητα λάθος. Μπορεί να αποτελεί έγκυρη παράφραση.

Για την αυτόματη γλωσσική ανάλυση χρησιμοποιήθηκε η βιβλιοθήκη [spaCy](#), με τα αντίστοιχα προεκπαιδευμένα μοντέλα για την ελληνική και την αγγλική γλώσσα. Το spaCy χρησιμοποιήθηκε για τον διαχωρισμό των προτάσεων σε λέξεις, την αναγνώριση των μερών του λόγου, την εξαγωγή μορφολογικών χαρακτηριστικών, τη συντακτική ανάλυση εξαρτήσεων και την αναγνώριση επώνυμων οντοτήτων.

Η ανάλυση πραγματοποιήθηκε ξεχωριστά για κάθε γλώσσα-στόχο. Για την EN→GR χρησιμοποιήθηκε ανάλυση ελληνικής μορφολογίας, ενώ για την GR→EN χρησιμοποιήθηκε διαφορετικό σύνολο χαρακτηριστικών, κατάλληλο για την αγγλική γλώσσα.

3.2 Δομικές ανακατασκευές στην EN→GR

Για την ελληνική έξοδο εξετάστηκαν:

- παθητικά ρήματα,
- ονοματικές γενικές,
- γενικές προσδιοριστών,
- επιθετικοί προσδιορισμοί,
- αναφορικοί δείκτες,
- αναφορικές προτάσεις,

- δείκτες υποτακτικής,
- υποτακτικοί σύνδεσμοι,
- προθέσεις,
- οριστικά άρθρα.

Για κάθε χαρακτηριστικό μετρήθηκε η απόκλιση μεταξύ της μετάφρασης και της αναφοράς, χωρίς οι αποκλίσεις αυτές να θεωρούνται αυτομάτως γραμματικά σφάλματα.

Ευρήματα

Στις τεχνικές που διατήρησαν την ποιότητα, οι δομικές διαφορές ήταν γενικά μικρές. Παρατηρήθηκαν μικρές μεταβολές στη χρήση παθητικών δομών, δομών γενικής, άρθρων και υποτακτικής, αλλά χωρίς αντίστοιχη αύξηση πραγματικών γραμματικών ασυμφωνιών.

Στις τεχνικές με μέτρια υποβάθμιση, οι δομικές αποκλίσεις αυξήθηκαν πριν αυξηθούν σημαντικά οι εσωτερικές ασυμφωνίες.

Αυτό δείχνει ότι η κβάντιση αρχικά επηρεάζει περισσότερο την επιλογή της διατύπωσης και της συντακτικής κατασκευής. Το μοντέλο μπορεί να απομακρύνεται από τη δομή της αναφοράς, διατηρώντας όμως μια εσωτερικά γραμματική πρόταση.

Οι πολύ μεγάλες αποκλίσεις στα άρθρα, στις προθέσεις και στους επιθετικούς προσδιορισμούς εμφανίστηκαν κυρίως στις αποτυχημένες 2-bit κβαντίσεις. Σε αυτές τις περιπτώσεις, οι αυξημένες τιμές συχνά συνδέονταν με υπερβολικά μεγάλες εξόδους, επαναλήψεις ή εκφυλισμένη παραγωγή μετάφρασης.

3.3 Δομικές ανακατασκευές στην GR→EN

Η ίδια ακριβώς μορφολογική ανάλυση δεν μπορούσε να χρησιμοποιηθεί στην αγγλική έξοδο, επειδή τα αγγλικά δεν διαθέτουν το ίδιο σύστημα πτώσεων και γραμματικής συμφωνίας ως προς το γένος, τον αριθμό και την πτώση.

Για την αγγλική έξοδο εξετάστηκαν:

- παθητική σύνταξη,
- κτητικές δομές,
- γενικές με **of**,
- επιθετικοί προσδιορισμοί,
- αναφορικές προτάσεις,
- απαρεμφατικοί δείκτες,
- προθέσεις,
- υποτακτικοί σύνδεσμοι,
- μετοχές,
- οριστικά άρθρα,
- τροπικά βοηθητικά ρήματα.

Παράλληλα εξετάστηκε η μεταβολή του μήκους της παραγόμενης μετάφρασης, επειδή μια μεγαλύτερη πρόταση περιέχει συνήθως περισσότερα άρθρα, προθέσεις, προσδιορισμούς και δευτερεύουσες προτάσεις. Μια αύξηση στη συχνότητα αυτών των στοιχείων δεν ερμηνεύτηκε αυτομάτως ως συντακτικό πρόβλημα, αλλά εξετάστηκε αν οφειλόταν σε μεγαλύτερη ή πιο αναλυτική διατύπωση.

Ευρήματα

Στα αγγλικά, αρκετές δομικές μεταβολές συνδέθηκαν έντονα με το μήκος της εξόδου.

Οι καλές κβαντίσεις του Llama 3 παρήγαγαν ελαφρώς μεγαλύτερες προτάσεις και παράλληλα περισσότερα άρθρα, προθέσεις και επιθετικούς προσδιορισμούς.

Οι κβαντίσεις του NLLB παρήγαγαν συχνά λίγο συντομότερες μεταφράσεις, με λιγότερα άρθρα και προθέσεις, χωρίς αντίστοιχη απώλεια στο COMET.

Για τον λόγο αυτό, οι μεταβολές αυτές ερμηνεύτηκαν περισσότερο ως:

- συμπύκνωση,
- αυξημένη αναλυτικότητα,
- αλλαγή ύφους,
- συντακτική αναδιατύπωση.

Δεν θεωρήθηκαν από μόνες τους ένδειξη γραμματικής αποτυχίας.

3.4 Εσωτερικές γραμματικές ασυμφωνίες

Για την ελληνική έξοδο εξετάστηκαν:

- συμφωνία επιθέτου–ουσιαστικού,
- συμφωνία άρθρου–ουσιαστικού,
- συμφωνία υποκειμένου–ρήματος.

Οι μετρικές υπολογίστηκαν ως ποσοστό ασυμφωνιών επί του αριθμού των συγκρίσιμων γραμματικών σχέσεων:

$$R_{\text{violation}} = \frac{N_{\text{violations}}}{N_{\text{opportunities}}} \times 100$$

Οι συγκεκριμένες μετρικές βρίσκονται πιο κοντά σε πραγματικά γραμματικά προβλήματα, επειδή εξετάζουν την εσωτερική συνέπεια της παραγόμενης πρότασης και όχι την ομοιότητά της με τη σύνταξη της αναφοράς.

Στις κβαντίσεις που διατήρησαν την ποιότητα, οι διαφορές από το Πλήρες Μοντέλο ήταν πρακτικά μηδενικές.

Οι σημαντικές αυξήσεις εμφανίστηκαν κυρίως στις σοβαρά υποβαθμισμένες παραλλαγές. Εκεί αυξήθηκαν οι ασυμφωνίες:

- επιθέτου–ουσιαστικού,
- άρθρου–ουσιαστικού,
- υποκειμένου–ρήματος.

Για την αγγλική έξοδο εξετάστηκαν:

- συμφωνία υποκειμένου–ρήματος,
- συμφωνία δεικτικής αντωνυμίας–ουσιαστικού,
- χρήση των **a/an** με ενικό ή πληθυντικό ουσιαστικό.

Οι αγγλικές μετρικές συμφωνίας παρέμειναν γενικά σταθερές στις επιτυχημένες κβαντίσεις.

Στις σοβαρά υποβαθμισμένες μεταφράσεις, οι μετρικές γραμματικής συμφωνίας παρέμειναν σε χαμηλές τιμές. Αυτό όμως δεν σημαίνει απαραίτητα ότι η μετάφραση είναι γραμματικά σωστή, επειδή ο συντακτικός αναλυτής μπορεί να εντοπίζει πολύ λίγες ολοκληρωμένες σχέσεις, όπως σχέσεις υποκειμένου–ρήματος. Για τον λόγο αυτό, τα ποσοστά ασυμφωνιών εξετάστηκαν μαζί με τον αριθμό των διαθέσιμων περιπτώσεων. Όταν αυτός ο αριθμός ήταν μικρός, η μετρική δεν θεωρήθηκε αρκετά αξιόπιστη για την εξαγωγή συμπεράσματος σχετικά με τη γραμματικότητα της μετάφρασης.

Επομένως, στην κατεύθυνση GR→EN δεν προέκυψε ασφαλές συμπέρασμα από τις μετρικές συμφωνίας για τις σοβαρά υποβαθμισμένες μεταφράσεις, και η κατάρρευση αποτυπώθηκε καθαρότερα μέσω των απωλειών περιεχομένου, των επαναλήψεων και της σημασιολογικής απομάκρυνσης.

3.5 Διατήρηση πληροφοριών

Στην τρίτη ομάδα εξετάστηκε η διατήρηση:

- επώνυμων οντοτήτων,
- κύριων ονομάτων,
- αριθμών,
- άρνησης (negation).

Για κάθε κατηγορία υπολογίστηκαν:

- η ανάκληση (recall), για πιθανές παραλείψεις,
- η ακρίβεια (precision), για πιθανές προσθήκες,
- η διαφορά από το Πλήρες Μοντέλο.

Η ανάλυση αυτή θεωρήθηκε περισσότερο ερμηνεύσιμη από τις απλές δομικές καταμετρήσεις, επειδή αφορά πληροφορίες που θα πρέπει κατά κανόνα να παραμένουν στη μετάφραση.

Ευρήματα

Στην κατεύθυνση EN→GR, οι περισσότερες επιτυχημένες κβαντίσεις διατήρησαν ικανοποιητικά τις βασικές πληροφορίες της πρότασης. Μικρές απώλειες εμφανίστηκαν κυρίως στα κύρια ονόματα και στις επώνυμες οντότητες.

Οι αριθμοί διατηρήθηκαν γενικά καλύτερα από τις υπόλοιπες κατηγορίες. Αυτό όμως δεν σημαίνει απαραίτητα ότι η μετάφραση ήταν συνολικά πιστή, καθώς ένας αριθμός μπορεί να αντιγραφεί σωστά ακόμη και μέσα σε μια κατά τα άλλα λανθασμένη πρόταση. Η άρνηση παρέμεινε επίσης σταθερή στις καλές κβαντίσεις, αλλά στις σοβαρά υποβαθμισμένες παραλλαγές εμφανίστηκαν σημαντικές απώλειες, οι οποίες μπορούσαν να αλλάξουν ουσιαστικά το νόημα της πρότασης.

Στην κατεύθυνση GR→EN, οι επιτυχημένες κβαντίσεις διατήρησαν γενικά τις οντότητες, τα κύρια ονόματα, τους αριθμούς και την άρνηση. Οι σημαντικές απώλειες εμφανίστηκαν κυρίως στις παραλλαγές όπου είχε ήδη υποβαθμιστεί έντονα η συνολική ποιότητα της μετάφρασης.

Συνολικά, στις καλές κβαντίσεις οι πρώτες αλλαγές εμφανίστηκαν κυρίως στον τρόπο διατύπωσης και στη δομή της πρότασης, χωρίς μεγάλη απώλεια πληροφοριών. Στις επιθετικές κβαντίσεις εμφανίστηκαν σοβαρές απώλειες περιεχομένου. Στην ελληνική έξοδο οι απώλειες αυτές συνοδεύτηκαν και από περισσότερες γραμματικές ασυμφωνίες, ενώ στην αγγλική έξοδο η υποβάθμιση αποτυπώθηκε καθαρότερα μέσω των παραλείψεων, των επαναλήψεων και της σημασιολογικής απομάκρυνσης.

4. Παραισθήσεις, παραλείψεις και πιστότητα της μετάφρασης

4.1 Στόχος της ανάλυσης

Η αξιολόγηση πιστότητας σχεδιάστηκε ώστε να εξετάσει αν η κβάντιση οδηγεί σε:

- παράλειψη πληροφορίας της πηγής,
- προσθήκη περιεχομένου που δεν υποστηρίζεται από την πηγή,
- επανάληψη ή εκφυλισμένη παραγωγή,
- μετάφραση σε λάθος γλώσσα,

- αντιγραφή της αρχικής πρότασης.

Οι αυτόματοι αυτοί δείκτες αντιμετωπίστηκαν ως **δείκτες κινδύνου** και όχι ως επιβεβαιωμένες περιπτώσεις παραίσθησης ή παράλειψης.

Αυτός ο διαχωρισμός είναι σημαντικός, επειδή μια λέξη χωρίς αυτόματη αντιστοίχιση δεν αποτελεί απαραίτητα παραίσθηση. Μπορεί να προέρχεται από παράφραση, διαφορετική μορφολογική μορφή ή ακόμα και αποτυχία του μηχανισμού αντιστοίχισης.

Για την εκτίμηση της στατιστικής αξιοπιστίας των διαφορών μεταξύ κάθε κβαντισμένης παραλλαγής και του αντίστοιχου Πλήρους Μοντέλου χρησιμοποιήθηκε paired bootstrap σε επίπεδο πρότασης. Με βάση την κατανομή των επαναδειγματοληπτικών διαφορών υπολογίστηκαν 95% διαστήματα εμπιστοσύνης. Όταν το διάστημα δεν περιλαμβάνει το μηδέν, η παρατηρούμενη διαφορά θεωρείται στατιστικά αξιόπιστη. Στην παρούσα φάση, η διαδικασία αυτή εφαρμόστηκε μόνο στην ανάλυση πιστότητας και όχι στις υπόλοιπες ενότητες της αξιολόγησης.

4.2 Αντιστοίχιση λέξεων με την προσέγγιση OTTAWA

Για την εκτίμηση των παραλείψεων και του μη υποστηριζόμενου περιεχομένου χρησιμοποιήθηκε μια υλοποίηση βασισμένη στην προσέγγιση [OTTAWA](#).

Η OTTAWA είναι μια μέθοδος αντιστοίχισης λέξεων που συνδέει τις λέξεις της πρότασης-πηγής με τις λέξεις της παραγόμενης μετάφρασης. Σε αντίθεση με μια απλή αντιστοίχιση, περιλαμβάνει και μια προσαρμοζόμενη κατάσταση **NULL**, στην οποία μπορούν να συνδεθούν λέξεις που δεν έχουν επαρκές αντίστοιχο στην άλλη πρόταση.

Στην παρούσα ανάλυση, οι λέξεις της πηγής και της μετάφρασης αναπαραστάθηκαν στον ίδιο (πολυγλωσσικό) διανυσματικό χώρο με τη χρήση του μοντέλου LaBSE. Στη συνέχεια, η αντιστοίχιση εφαρμόστηκε και προς τις δύο κατευθύνσεις:

- από την πηγή προς τη μετάφραση,
- από τη μετάφραση προς την πηγή.

Με βάση τις συνδέσεις με το NULL υπολογίστηκαν δύο βασικοί δείκτες:

- **Κίνδυνος παράλειψης:** λέξεις ή πληροφορίες της πηγής που δεν βρίσκουν επαρκές αντίστοιχο στην παραγόμενη μετάφραση.
- **Κίνδυνος μη υποστηριζόμενου περιεχομένου:** λέξεις ή τμήματα της μετάφρασης που δεν βρίσκουν επαρκή στήριξη στην πρόταση-πηγή.

Οι δείκτες αυτοί δεν χρησιμοποιήθηκαν μόνοι τους. Εμπλουτίστηκαν με πρόσθετες πληροφορίες που βοηθούν στην αναγνώριση διαφορετικών μορφών αποτυχίας:

- σημασιολογική ομοιότητα της μετάφρασης με την αναφορά,
- μήκος της παραγόμενης εξόδου,
- διατήρηση οντοτήτων, αριθμών και άρνησης,
- επαναλήψεις και εκφυλισμένη παραγωγή,
- παραγωγή σε λάθος γλώσσα,
- αντιγραφή λέξεων ή τμημάτων της πηγής.

Με αυτόν τον τρόπο, η ανάλυση δεν περιορίστηκε στο αν κάποιες λέξεις δεν αντιστοιχίστηκαν, αλλά προσπάθησε να διακρίνει αν η αποτυχία σχετιζόταν περισσότερο με παράλειψη, μη υποστηριζόμενη προσθήκη, επανάληψη, αντιγραφή της πηγής ή παραγωγή σε λάθος γλώσσα.

4.3 Γενικά αποτελέσματα

Για κάθε πρόταση, η έξοδος της κβαντισμένης παραλλαγής συγκρίθηκε με την έξοδο του αντίστοιχου πλήρους μοντέλου. Έτσι, η ανάλυση επικεντρώθηκε στις πρόσθετες παραλείψεις ή προσθήκες που εμφανίστηκαν μετά την κβάντιση και όχι σε προβλήματα που υπήρχαν ήδη στο αρχικό μοντέλο.

Οι περισσότερες κβαντίσεις που διατήρησαν τη συνολική μεταφραστική ποιότητα δεν παρουσίασαν ουσιαστική αύξηση ούτε στις παραλείψεις ούτε στο μη υποστηριζόμενο περιεχόμενο. Ειδικότερα, στις μεθόδους με απώλεια COMET έως 0,02, οι διαφορές από το Πλήρες Μοντέλο παρέμειναν πολύ κοντά στο μηδέν και στις δύο κατευθύνσεις μετάφρασης.

Το αποτέλεσμα αυτό δείχνει ότι η κβάντιση δεν οδηγεί από μόνη της σε ουσιαστική αύξηση των δεικτών κινδύνου παραίσθησης ή παράλειψης. Τα προβλήματα αυτά εμφανίστηκαν κυρίως στις επιθετικές κβαντίσεις, όπου είχε ήδη υποβαθμιστεί σημαντικά η συνολική ποιότητα της μετάφρασης. Στις περιπτώσεις αυτές, η μορφή της υποβάθμισης διέφερε ανάλογα με την κατεύθυνση μετάφρασης.

4.4 Μορφή υποβάθμισης στην EN→GR

Στην κατεύθυνση EN→GR, οι σοβαρά υποβαθμισμένες μεταφράσεις παρουσίασαν ελαφρώς μεγαλύτερο κίνδυνο παράλειψης από τον κίνδυνο μη υποστηριζόμενου περιεχομένου. Το βασικό πρόβλημα δεν ήταν συνήθως η παραγωγή νέου ελληνικού περιεχομένου χωρίς στήριξη από την πηγή, αλλά η αδυναμία του μοντέλου να αποδώσει ολοκληρωμένα την αγγλική πρόταση στα ελληνικά.

Σε αρκετές αποτυχημένες παραλλαγές παρατηρήθηκαν:

- διατήρηση λέξεων ή ολόκληρων τμημάτων στα αγγλικά,
- παραγωγή μικτής γλώσσας,
- αντιγραφή της αρχικής πρότασης,
- παράλειψη πληροφοριών που έπρεπε να μεταφραστούν.

Επομένως, η υποβάθμιση στην EN→GR εκφράστηκε κυρίως ως ελλιπής μετάφραση, αντιγραφή της πηγής και παραγωγή σε λάθος γλώσσα, παρά ως μοτίβο πιθανής παραίσθησης.

4.5 Μορφή υποβάθμισης στην GR→EN

Στην κατεύθυνση GR→EN, οι σοβαρά υποβαθμισμένες μεταφράσεις παρέμεναν συνήθως στην αγγλική γλώσσα, αλλά απομακρύνονταν περισσότερο από το περιεχόμενο της ελληνικής πηγής. Σε αυτή την περίπτωση, ο κίνδυνος μη υποστηριζόμενου περιεχομένου ήταν γενικά μεγαλύτερος από τον κίνδυνο παράλειψης.

Τα βασικά προβλήματα που παρατηρήθηκαν ήταν:

- επαναλήψεις λέξεων ή φράσεων,
- υπερβολικά μεγάλες και εκφυλισμένες συνέχειες,
- παραγωγή πληροφοριών που δεν υπήρχαν στην πηγή,
- σημασιολογική απομάκρυνση από το αρχικό κείμενο.

Η υποβάθμιση στην GR→EN ήταν επομένως πιο κοντά στο μοτίβο πιθανής παραίσθησης: το μοντέλο συνέχιζε να παράγει αγγλικό κείμενο, αλλά η έξοδος γινόταν επαναληπτική ή περιείχε πληροφορίες χωρίς σαφή σύνδεση με την ελληνική πρόταση.

4.6 Encoder–decoder και decoder-only μοντέλα

Εξετάστηκε η υπόθεση ότι:

- τα encoder–decoder μοντέλα εμφανίζουν κυρίως παραλείψεις ή επαναλήψεις,
- τα decoder-only μοντέλα εμφανίζουν κυρίως παραισθήσεις.

Τα αποτελέσματα υποστηρίζουν μόνο εν μέρει αυτή τη διάκριση.

Σε συγκρίσιμα επίπεδα μέτριας υποβάθμισης, το NLLB παρουσίασε ελαφρώς μεγαλύτερη τάση προς παραλείψεις. Τα decoder-only μοντέλα παρουσίασαν ελαφρώς μεγαλύτερη τάση προς μη υποστηριζόμενο περιεχόμενο (ένδειξη πιθανής παραίσθησης).

Ωστόσο, η σύγκριση έχει έναν σημαντικό περιορισμό: το NLLB δεν εισήλθε σε σοβαρό καθεστώς κατάρρευσης, ενώ αρκετές 2-bit παραλλαγές των decoder-only μοντέλων κατέρρευσαν. Επομένως, δεν υπάρχει άμεση σύγκριση encoder–decoder και decoder-only μοντέλων στο ίδιο επίπεδο σοβαρής αποτυχίας.

Επιπλέον, η επανάληψη δεν αποτέλεσε κυρίαρχη μορφή υποβάθμισης στο NLLB. Οι ισχυρότερες περιπτώσεις επανάληψης και εκφυλισμένης παραγωγής εμφανίστηκαν σε αποτυχημένες παραλλαγές των decoder-only μοντέλων.

Τα decoder-only μοντέλα επίσης δεν παρουσίασαν την ίδια μορφή υποβάθμισης και στις δύο κατευθύνσεις:

- στην EN→GR κυριάρχησαν οι παραλείψεις, η αντιγραφή της πηγής και η παραγωγή σε λάθος γλώσσα,
- στην GR→EN κυριάρχησαν οι επαναλήψεις και οι μη υποστηριζόμενες συνέχειες.

Συνεπώς, δεν προκύπτει ένας αυστηρός διαχωρισμός με βάση την αρχιτεκτονική του μοντέλου. Ο τρόπος με τον οποίο υποβαθμίζεται η μετάφραση φαίνεται να εξαρτάται από τον συνδυασμό της αρχιτεκτονικής, της γλώσσας-στόχου, του επιπέδου συμπίεσης και της συγκεκριμένης μεθόδου κβάντισης.

5. Συνολικό συμπέρασμα της αξιολόγησης

Η πολυεπίπεδη αξιολόγηση έδειξε ότι οι γενικές μετρικές COMET και chrF++ αποτυπώνουν με συνέπεια τη συνολική επίδραση της κβάντισης, αλλά δεν αρκούν για να εξηγήσουν τον τρόπο με τον οποίο αποτυγχάνει ένα μοντέλο.

Οι επιτυχημένες 4-bit και 8-bit κβαντίσεις:

- διατήρησαν σε μεγάλο βαθμό τη συνολική ποιότητα,
- δεν παρουσίασαν σταθερή αδυναμία σε συγκεκριμένη γλωσσική πρόκληση,
- δεν αύξησαν ουσιαστικά τις γραμματικές ασυμφωνίες,
- διατήρησαν τις περισσότερες κρίσιμες πληροφορίες,
- δεν παρουσίασαν πρακτικά σημαντική αύξηση των δεικτών κινδύνου παραίσθησης ή παράλειψης.

Οι πρώτες μικρές επιπτώσεις εμφανίστηκαν κυρίως ως:

- αλλαγές στη συντακτική διατύπωση,
- διαφοροποίηση του μήκους της εξόδου,
- μικρή ευαισθησία στη διατήρηση κύριων ονομάτων και οντοτήτων.

Οι σοβαρές επιπτώσεις εμφανίστηκαν κυρίως στις επιθετικές 2-bit κβαντίσεις και περιλάμβαναν:

- απώλεια σημασιολογικής κάλυψης,
- γραμματικές ασυμφωνίες, κυρίως στην ελληνική έξοδο,
- παραλείψεις,
- μη υποστηριζόμενες προσθήκες,
- επαναλήψεις,
- παραγωγή σε λάθος γλώσσα,
- αντιγραφή της πηγής.

Το NLLB παρουσίασε τη μεγαλύτερη ανθεκτικότητα, ενώ οι decoder-only αρχιτεκτονικές εμφάνισαν μεγαλύτερη μεταβλητότητα στις επιθετικές κβαντίσεις.

Τέλος, η κατεύθυνση μετάφρασης αποδείχθηκε ιδιαίτερα σημαντική. Η $EN \rightarrow GR$ ήταν περισσότερο ευάλωτη σε παραγωγή σε λάθος γλώσσα, αντιγραφή της πηγής και παραλείψεις, ενώ η $GR \rightarrow EN$ παρουσίασε συχνότερα επαναλήψεις, εκφυλισμένη παραγωγή και μη υποστηριζόμενες συνέχειες.

Επομένως, η επίδραση της κβάντισης δεν μπορεί να περιγραφεί μόνο ως μια ενιαία πτώση της βαθμολογίας. Πρόκειται για ένα σύνολο φαινομένων που εξαρτώνται από την αρχιτεκτονική, τη μέθοδο κβάντισης, τη γλώσσα-στόχο και το επίπεδο συμπίεσης.